

Infraestrutura para Projetos de Big Data — Aula 01

Resolução comentada das questões

Cada questão aparece primeiro com o enunciado original. Logo abaixo vêm o gabarito e a justificativa de cada alternativa, explicando por que ela está certa ou errada. Ao final de cada questão, o item **Para revisar** indica o slide da Aula 01 que trata do assunto.

Dica de leitura: tente resolver novamente a questão antes de ler a justificativa.

Questão 1

Em relação aos 5 Vs do Big Data, selecione as alternativas corretas.

a. Volume está relacionado à escala massiva de dados (por exemplo, de terabytes a petabytes). b. Velocidade trata do ritmo de geração e do tempo necessário para processar os dados (batch vs streaming). c. Variedade descreve a diversidade de formatos, como estruturados, semiestruturados e não-estruturados. d. Veracidade significa que todo dado é perfeito e livre de ruído.

✓ **Gabarito: a, b, c**

Justificativa

- **a) Correta.** Volume é a escala dos dados. Mais do que um número fixo (terabytes ou petabytes), o que importa é o ponto em que o volume passa da capacidade de uma única máquina.
- **b) Correta.** Velocidade envolve dois ritmos: o de geração dos dados e o prazo aceitável para processá-los. É daí que vem a escolha entre batch e streaming.
- **c) Correta.** Variedade é a mistura de dados estruturados, semiestruturados e não estruturados, que exige formatos e ferramentas diferentes.
- **d) Incorreta.** É o contrário. Veracidade trata da **confiabilidade** dos dados, levando em conta ruído, lacunas e vieses. Esse V existe justamente porque dados reais **não** são perfeitos.

Lembre-se: o quinto V, que não aparece nas alternativas, é **Valor**, o retorno que justifica o custo da infraestrutura. **Para revisar:** slide "O que caracteriza um problema de Big Data".

Questão 2

Sobre o pipeline de dados em projetos de Big Data, selecione as alternativas corretas.

a. Coleta (ingestão) de dados a partir de fontes como APIs, IoT e logs. b. Armazenamento em repositórios como Data Lake, Data Warehouse ou storage em nuvem. c. Processamento (ETL/ELT) em modo batch ou streaming, preparando dados para análise. d. Visualização/comunicação por dashboards, BI, relatórios ou alertas.

✓ **Gabarito: a, b, c, d**

Justificativa

Todas as alternativas descrevem camadas da plataforma de dados, na ordem em que o dado passa por elas:

- **a) Correta.** Coleta/ingestão: é onde os dados nascem (APIs, IoT, logs, sistemas transacionais).
- **b) Correta.** Armazenamento: Data Lake, Data Warehouse, Lakehouse e object storage em nuvem.
- **c) Correta.** Processamento: ETL/ELT, em lote ou em fluxo, para deixar o dado pronto para análise.
- **d) Correta.** Consumo/visualização: dashboards, BI, relatórios, alertas e modelos de ML.

Saiba mais: além dessas quatro camadas, algumas funções atravessam o pipeline inteiro. São elas a orquestração (por exemplo, com Airflow), a segurança e a LGPD, a observabilidade e o controle de custos (FinOps). **Para revisar:** slide "Anatomia de uma plataforma de dados".

Questão 3

Sobre tipos de dados e exemplos de fontes, selecione as alternativas corretas.

a. Arquivos CSV e tabelas em bancos relacionais são exemplos comuns de dados estruturados. b. JSON e XML são exemplos típicos de dados semiestruturados. c. Imagens e vídeos são exemplos comuns de dados não-estruturados. d. Logs de aplicações são sempre dados estruturados, pois já vêm em colunas fixas.

✓ **Gabarito: a, b, c**

Justificativa

- **a) Correta.** CSV e tabelas relacionais têm esquema fixo, com linhas e colunas definidas. Por isso são estruturados.
- **b) Correta.** JSON e XML se organizam por chaves e tags, mas o esquema é flexível. Por isso são semiestruturados.
- **c) Correta.** Imagens, vídeos e áudio não têm uma estrutura de tabela. Por isso são não estruturados.
- **d) Incorreta.** Logs costumam ser **semiestruturados** ou até texto livre. O formato varia de uma aplicação para outra, e muitas vezes é preciso fazer parsing (com regex, por exemplo) para extrair os campos. O erro está na palavra "sempre".

Para revisar: slides "O que caracteriza um problema de Big Data" e "Camada 1 — Coleta: onde os dados nascem".

Questão 4

Sobre tecnologias de coleta/ingestão de dados, selecione as alternativas corretas.

a. Apache Kafka é amplamente usado para streaming de dados com alta taxa de transferência (throughput). b. Apache NiFi pode automatizar fluxos de dados entre sistemas (ingestão e roteamento). c. CDC (Change Data Capture) captura mudanças em bancos de dados para alimentar pipelines quase em tempo real. d. Apache Spark é principalmente uma ferramenta de visualização de dashboards.

✓ **Gabarito: a, b, c**

Justificativa

- **a) Correta.** Kafka é uma plataforma de log distribuído, feita para streaming com alto throughput e retenção de eventos.

- **b) Correta.** NiFi automatiza fluxos de dados entre sistemas (ingestão, transformações leves e roteamento) usando uma interface visual.
- **c) Correta.** O CDC (por exemplo, com Debezium) lê o log de transações do banco e publica as inserções, atualizações e exclusões quase em tempo real, sem sobrecarregar o sistema de origem com consultas.
- **d) Incorreta.** Spark é um **motor de processamento distribuído**, usado para batch, SQL, streaming e ML. Ele pertence à camada de processamento, e não à de visualização.

Para revisar: slide "O que se usa: ferramentas da camada de ingestão".

Questão 5

Comparando Data Warehouse e Data Lake, selecione as alternativas corretas.

a. Data Warehouse costuma trabalhar com dados estruturados e pré-processados, otimizados para consultas analíticas SQL. b. Data Lake tende a armazenar dados brutos no formato original e aceita dados estruturados e não-estruturados. c. Data Warehouse é tipicamente schema-on-read, definindo o esquema apenas no momento da consulta. d. Data Lake exige que todos os dados passem por modelagem rígida antes de serem armazenados.

✓ **Gabarito: a, b**

Justificativa

- **a) Correta.** O Data Warehouse guarda dados estruturados, limpos e modelados, e é otimizado para consultas SQL analíticas.
- **b) Correta.** O Data Lake guarda dados brutos no formato original, de qualquer tipo, geralmente em object storage de baixo custo.
- **c) Incorreta.** O Data Warehouse é **schema-on-write**: o esquema é validado quando o dado é gravado. Schema-on-read é característica do **Data Lake**. A alternativa inverte os conceitos.
- **d) Incorreta.** O Data Lake aceita dados **sem** modelagem prévia. Modelagem rígida antes da carga é característica do Data Warehouse.

Para memorizar: *Warehouse* → *Write* (o esquema é validado na gravação). *Lake* → *Read* (o esquema é interpretado na leitura). **Para revisar:** slide "Data Warehouse × Data Lake × Lakehouse".

Questão 6

Sobre Data Lakehouse, selecione as alternativas corretas.

a. Busca combinar flexibilidade do Data Lake com desempenho e governança típicos de um Data Warehouse. b. Pode oferecer transações ACID sobre dados armazenados no lake. c. É uma alternativa pensada para unificar governança e performance em uma plataforma de dados. d. Não é compatível com dados em storage em nuvem, sendo restrita a on-premises.

✓ **Gabarito: a, b, c**

Justificativa

- **a) Correta.** O Lakehouse une o armazenamento barato e flexível do Data Lake à performance e à governança do Data Warehouse.
- **b) Correta.** Formatos de tabela abertos, como Delta Lake, Apache Iceberg e Apache Hudi, oferecem **transações ACID** sobre os arquivos do lake, além de recursos como histórico de versões (time travel) e evolução de esquema.
- **c) Correta.** A ideia é ter uma única plataforma, em vez de manter um lake e um warehouse separados, com cópias duplicadas dos dados.
- **d) Incorreta.** O Lakehouse surgiu justamente sobre **object storage em nuvem** (S3, ADLS, GCS). Ele também pode rodar on-premises, mas não fica restrito a isso.

Para revisar: slide "Data Warehouse × Data Lake × Lakehouse".

Questão 7

Sobre processamento em lote (batch) e em tempo real (streaming), selecione as alternativas corretas.

a. Batch processa grandes volumes acumulados em intervalos (horas/dias), sendo comum em ETL e relatórios periódicos. b. Streaming processa continuamente à medida que os dados chegam, com baixa latência (ms a segundos). c. Streaming é inadequado para casos como detecção de fraudes ou monitoramento de IoT. d. Batch sempre exige respostas em milissegundos para cada evento individual.

✓ **Gabarito: a, b**

Justificativa

- **a) Correta.** O batch processa dados acumulados em janelas de horas ou dias. É comum em ETL noturno, fechamento contábil e relatórios periódicos.
- **b) Correta.** O streaming processa cada evento, ou pequenos lotes, conforme os dados chegam, com latência de milissegundos a segundos.
- **c) Incorreta.** Detecção de fraude e monitoramento de IoT são **exemplos clássicos** de streaming: a resposta precisa sair antes de a transação ser concluída ou antes de o equipamento falhar.
- **d) Incorreta.** O batch aceita latência alta por natureza. Responder em milissegundos a cada evento é característica do **streaming**.

Saiba mais: a arquitetura **Lambda** mantém dois caminhos (lote e tempo real) e depois concilia os resultados. A **Kappa** usa só streaming e reprocessa os dados a partir do log. Como o streaming custa mais para operar, ele deve ser escolhido quando a baixa latência de fato gera valor para o negócio.

Para revisar: slide "Batch × streaming: a decisão que define o custo".

Questão 8

Sobre visualização e comunicação de dados, selecione as alternativas corretas.

a. Clareza ajuda a reduzir ruído visual: cada elemento do dashboard deve apoiar o entendimento. b. Contexto (benchmarks, metas, períodos anteriores) ajuda a dar significado aos números apresentados. c. Interatividade (filtros, drill-down) pode facilitar exploração e tomada de decisão. d. A melhor prática é evitar qualquer tipo de interação para não "distrair" o usuário.

✓ **Gabarito: a, b, c**

Justificativa

- **a) Correta.** Clareza significa eliminar o que não ajuda a entender os dados, como excesso de cores, efeitos 3D e gráficos redundantes.
- **b) Correta.** Sem uma referência (meta, período anterior ou benchmark), não dá para saber se um número é bom ou ruim.
- **c) Correta.** Filtros e drill-down permitem sair do resumo e chegar ao detalhe sem precisar de outro relatório.
- **d) Incorreta.** Uma interatividade **bem planejada** facilita a exploração. O problema está no excesso de controles, e não na interação em si. A palavra "qualquer" torna a afirmação falsa.

Para revisar: slide "Camada 4 — Consumo: do dado ao insight".

Questão 9

Sobre on-premises versus cloud, selecione as alternativas corretas.

a. On-premises tende a exigir CAPEX inicial maior e equipe dedicada para manutenção da infraestrutura. b. Cloud costuma oferecer escalabilidade elástica sob demanda e modelo de custo por uso (OPEX). c. Cloud elimina totalmente a necessidade de governança, segurança e controle de acesso. d. Em cloud, custos recorrentes podem crescer se não houver monitoramento e otimização.

✓ **Gabarito: a, b, d**

Justificativa

- **a) Correta.** No on-premises, o hardware é comprado antecipadamente (CAPEX alto e ciclo de compra longo), e é preciso ter uma equipe para operar o datacenter.
- **b) Correta.** A nuvem oferece elasticidade sob demanda, com pagamento pelo uso (OPEX).
- **c) Incorreta.** Na nuvem vale o **modelo de responsabilidade compartilhada**. O provedor protege a infraestrutura, mas o cliente continua responsável pelo controle de acesso (IAM), pela criptografia, pelas configurações e pela conformidade com a LGPD.
- **d) Correta.** O custo recorrente cresce com o uso. Recursos ociosos, tráfego de saída (egress) e armazenamento esquecido aumentam a fatura. É por isso que existe a prática de FinOps.

Saiba mais: escolher entre on-premises e nuvem é uma questão de critérios, e não de preferência. Os principais são o perfil da carga (constante ou sazonal), a maturidade do time, as exigências regulatórias e o prazo em que o investimento se paga. **Para revisar:** slides "On-premises × nuvem: critérios, não preferências" e "Custos: dimensionar antes de contratar".

Questão 10

Sobre nuvem híbrida e multi-cloud, selecione as alternativas corretas.

a. Nuvem híbrida combina infraestrutura local com serviços de nuvem pública, podendo manter dados sensíveis on-premises. b. Multi-cloud usa serviços de múltiplos provedores e pode reduzir risco de vendor lock-in. c. Híbrida e multi-cloud são sinônimos: sempre significam usar dois provedores de nuvem. d. Multi-cloud impede completamente problemas de integração e observabilidade.

✓ **Gabarito: a, b**

Justificativa

- **a) Correta.** A nuvem híbrida combina infraestrutura local com nuvem pública. Um uso típico é manter dados sensíveis on-premises e usar a nuvem para ter processamento elástico.
- **b) Correta.** Multi-cloud é usar mais de um provedor de nuvem, o que reduz a dependência de um único fornecedor (vendor lock-in).
- **c) Incorreta.** São conceitos **diferentes**. Na nuvem híbrida, combina-se infraestrutura local com nuvem. No multi-cloud, usa-se mais de um provedor de nuvem. Os dois modelos podem existir juntos, mas não são sinônimos.
- **d) Incorreta.** O multi-cloud **aumenta** a complexidade de integração, rede, identidade e observabilidade. Ganha-se flexibilidade em troca de mais trabalho operacional.

Para revisar: slide "On-premises × nuvem: critérios, não preferências".

Questão 11

No modelo IaaS, qual alternativa descreve melhor a divisão de responsabilidades? Selecione as alternativas corretas.

a. O provedor gerencia a infraestrutura física; o cliente gerencia sistema operacional e aplicações. b. O provedor entrega a aplicação pronta via navegador; o cliente só usa o software. c. O cliente não tem controle sobre rede e SO, pois tudo é gerenciado como plataforma. d. O provedor gerencia apenas o código-fonte do cliente e os pipelines de CI/CD.

✓ **Gabarito: a** (apenas uma alternativa correta)

Justificativa

- **a) Correta.** No IaaS, o provedor cuida do hardware, da rede física, do armazenamento e da virtualização. O cliente cuida do sistema operacional, do middleware, do runtime, das aplicações e dos dados.
- **b) Incorreta.** Essa alternativa descreve o **SaaS**.
- **c) Incorreta.** No IaaS, o cliente **controla** o sistema operacional e boa parte da rede virtual (sub-redes, regras de firewall). Deixar tudo "gerenciado como plataforma" é característica do **PaaS**.
- **d) Incorreta.** Em nenhum dos modelos o provedor gerencia o código do cliente. Os pipelines de CI/CD são responsabilidade do cliente, mesmo quando ele usa um serviço gerenciado para executá-los.

Para memorizar: quanto mais você sobe de IaaS para PaaS e depois para SaaS, mais responsabilidades passam para o provedor e menos ficam com você. **Para revisar:** slide "IaaS, PaaS e SaaS: quem gerencia o quê".

Questão 12

Sobre PaaS, selecione as alternativas corretas.

a. Abstrai grande parte da infraestrutura, permitindo focar no código e no deploy da aplicação. b. Pode oferecer serviços integrados como banco de dados, filas, cache e CI/CD. c. Pode facilitar escalabilidade

automática sem configuração manual detalhada do servidor. d. Exige que o cliente compre e instale servidores físicos no próprio datacenter para funcionar.

✓ **Gabarito: a, b, c**

Justificativa

- **a) Correta.** O PaaS esconde os servidores e o sistema operacional, e o time se concentra no código e no deploy.
- **b) Correta.** Plataformas PaaS costumam oferecer bancos de dados, filas, cache e pipelines de CI/CD já integrados.
- **c) Correta.** O escalonamento automático é definido por regras (uso de CPU, número de requisições), sem ajuste manual do servidor.
- **d) Incorreta.** Comprar e instalar servidores físicos é característica do **on-premises**. No PaaS, o cliente não tem hardware próprio.

Exemplos na área de dados: Azure Databricks, AWS EMR Serverless, Google Dataproc e Azure Synapse. **Para revisar:** slides "IaaS, PaaS e SaaS: quem gerencia o quê" e "Os três modelos aplicados a projetos de dados".

Questão 13

Sobre SaaS, selecione as alternativas corretas.

a. Normalmente é acessado via navegador e reduz a necessidade de instalação e manutenção local. b. O provedor gerencia toda a stack (infra, plataforma e software), enquanto o usuário consome o serviço. c. Atualizações e correções são aplicadas pelo provedor, geralmente de forma automática. d. Favorece colaboração, pois equipes podem trabalhar em tempo real em ferramentas online.

✓ **Gabarito: a, b, c, d**

Justificativa

- **a) Correta.** O acesso é feito pelo navegador, sem instalação local.
- **b) Correta.** O provedor gerencia toda a pilha. O usuário só consome o serviço e cuida dos próprios dados e acessos.
- **c) Correta.** As atualizações e correções são aplicadas pelo provedor, sem que o usuário precise fazer nada.
- **d) Correta.** Com ferramentas online, a equipe consegue editar e compartilhar o trabalho em tempo real.

Atenção: mesmo no SaaS, a **governança dos dados** continua sendo responsabilidade do cliente. Isso inclui definir quem tem acesso, saber onde os dados ficam armazenados e cumprir a LGPD. **Para revisar:** slide "IaaS, PaaS e SaaS: quem gerencia o quê".

Questão 14

Sobre ferramentas do ecossistema de Big Data, selecione as alternativas corretas.

a. Airflow é uma ferramenta comum de orquestração de workflows/pipelines de dados. b. Presto/Trino é usado para consultas distribuídas (query engine) sobre diferentes fontes de dados. c. Grafana é um framework de processamento distribuído equivalente ao Apache Spark. d. Apache Atlas é associado a governança e catálogo/linhagem de dados.

✅ **Gabarito: a, b, d**

Justificativa

- **a) Correta.** O Airflow orquestra pipelines na forma de DAGs, com agendamento, dependências entre tarefas e novas tentativas em caso de falha.
- **b) Correta.** Presto/Trino é um motor de SQL distribuído que consulta várias fontes (lake, bancos relacionais, Kafka) sem precisar mover os dados.
- **c) Incorreta.** O Grafana é uma ferramenta de **visualização e monitoramento**, usada para montar dashboards de métricas e logs. Ele não faz processamento distribuído e não substitui o Spark.
- **d) Correta.** O Apache Atlas é usado em governança de dados: catálogo de metadados, classificação e linhagem (de onde o dado veio e por quais transformações passou).

Para associar cada ferramenta à sua camada: Airflow faz a orquestração. Trino é um motor de SQL distribuído. Grafana cuida da observabilidade e dos dashboards. Atlas atende à governança, com catálogo e linhagem. **Para revisar:** slides "Anatomia de uma plataforma de dados", "De MapReduce ao ecossistema atual" e "Segurança, governança e LGPD".

Questão 15

Sobre desafios e tendências em infraestrutura para Big Data, selecione as alternativas corretas.

a. FinOps surge para ajudar a controlar e otimizar custos em cloud, que podem escalar rapidamente. b. Data Mesh propõe descentralizar a ownership de dados por domínios de negócio. c. Lakehouse architecture busca convergir Data Lakes e Data Warehouses em uma plataforma unificada. d. Real-time analytics e uso de IA (incluindo IA generativa) tendem a crescer em projetos modernos.

✅ **Gabarito: a, b, c, d**

Justificativa

- **a) Correta.** FinOps é uma prática que reúne as áreas de finanças, engenharia e negócio para dar visibilidade aos gastos com nuvem e otimizá-los.
- **b) Correta.** O Data Mesh distribui a responsabilidade pelos dados entre os domínios de negócio. Cada domínio trata seus dados como um produto, apoiado por uma plataforma self-service e por uma governança federada, isto é, com regras comuns e aplicação descentralizada.
- **c) Correta.** O Lakehouse busca unificar Data Lake e Data Warehouse em uma única plataforma (veja a Questão 6).
- **d) Correta.** A demanda por análises em tempo real e por cargas de IA, incluindo IA generativa, aumenta a pressão sobre armazenamento, rede e GPUs.

Para revisar: slides "Custos: dimensionar antes de contratar" e "Síntese e próximos passos".

Gabarito resumido

Questão	Corretas	Questão	Corretas	Questão	Corretas
1	a, b, c	6	a, b, c	11	a
2	a, b, c, d	7	a, b	12	a, b, c
3	a, b, c	8	a, b, c	13	a, b, c, d
4	a, b, c	9	a, b, d	14	a, b, d
5	a, b	10	a, b	15	a, b, c, d

Estratégia de prova: desconfie de alternativas com palavras absolutas, como "sempre", "qualquer", "totalmente" e "impede completamente". Nesta lista, todas elas estavam incorretas.